

Price Disparity between Healthy and Processed Foods as a Predictor of Obesity Rates in the USA: An Analysis with USDA and BRFSS Public Data

Evandro Barreto¹

and

Kaiky de Souza Lima¹

Universidade Tecnológica Federal do Paraná, Brazil
{evandrobarreto, kaiky}@alunos.utfpr.edu.br

Abstract. Obesity is one of the most pressing global public health challenges, with socioeconomic factors playing a decisive role in its prevalence. This study investigates whether the price disparity between healthy and ultra-processed foods is a statistically significant predictor of obesity rates across American states. We integrate two public datasets: the Behavioral Risk Factor Surveillance System (BRFSS), provided by the CDC, which contains time-series indicators of obesity, fruit and vegetable consumption, and physical activity among American adults; and the Food-at-Home Monthly Area Prices dataset, provided by the USDA, which monitors regional monthly prices of household food items disaggregated by geographic area. We conduct an exploratory and correlational analysis to investigate whether variations in healthy food prices and income level are statistically associated with obesity rates across geographic regions. Subsequently, a regression model is applied to quantify the magnitude of this impact. Additionally, income level is examined as a potential moderating factor in the relationship between food prices and obesity risk. We hypothesize that sustained increases in fruit and vegetable prices are positively associated with higher obesity rates, and that lower-income populations are disproportionately affected. This work is aligned with the topics of Data Mining Applications, Machine Learning Applications, Time-Series Analysis, and Supervised Learning.

CCS Concepts: • **Computing methodologies** → **Machine learning**; *Supervised learning*.

Keywords: obesity, food prices, machine learning, classification, supervised learning, BRFSS, USDA, data mining

1. INTRODUCTION

A obesidade constitui um dos maiores desafios contemporâneos de saúde pública, sendo substancialmente agravada por variáveis macroeconômicas.

Embora a relação entre custo alimentar e obesidade seja intuitivamente sugerida na literatura, a principal lacuna metodológica reside na integração sistemática de bases de dados epidemiológicas e econômicas díspares para atestar esse fenômeno de forma quantitativa e replicável. Este artigo aborda essa lacuna por meio de um pipeline analítico preditivo que combina dados públicos do USDA e do CDC/BRFSS.

As seguintes perguntas de pesquisa orientam o estudo:

- P1:** Existe relação mensurável e estatisticamente significativa entre o custo de alimentos saudáveis (preço de frutas e vegetais) e a faixa de renda da população com os índices de obesidade nos estados norte-americanos?

Copyright©2025 Permission to copy without fee all or part of the material printed in KDMiLe is granted provided that the copies are not made or distributed for commercial advantage, and that notice is given that copying is by permission of the Sociedade Brasileira de Computação.

As hipóteses testadas são:

- H1:** A elevação sustentada nos preços médios de frutas e vegetais está positivamente associada ao aumento das taxas de obesidade.
- H2:** Categorias específicas de grupos de alimentos apresentam variações de preço com impacto diferenciado nos índices de obesidade.
- H3:** Populações com menor faixa de renda apresentam maiores índices de obesidade, sendo a renda um fator moderador na relação entre custo de alimentos saudáveis e risco de obesidade.

2. RELATED WORK

Xu et al. [Xu et al. 2014] mostraram que a queda dos preços relativos dos alimentos explica cerca de 18% do aumento da obesidade adulta nos EUA entre 1976 e 2001, motivando o uso de séries temporais por estado adotado neste trabalho (H1).

Finkelstein et al. [Finkelstein et al. 2014] revisaram políticas de preços alimentares e concluíram que subsídios a frutas e vegetais para populações de baixa renda produzem os resultados mais consistentes na redução da obesidade, fundamentando H1 e H3.

Canales et al. [Canales et al. 2021] documentaram que lojas de conveniência no Delta do Mississippi praticam preços até 95% maiores para alimentos saudáveis do que supermercados, evidenciando como o ambiente varejista local cria barreiras diferenciadas de acesso e embasando H2.

Nossa contribuição integra essas perspectivas em um pipeline unificado com dados públicos do BRFSS e do USDA para quantificar a relação entre disparidade de preços e obesidade no nível estadual.

3. DATA

3.1 Dataset 1: Nutrition, Physical Activity and Obesity (CDC/BRFSS)

O Behavioral Risk Factor Surveillance System (BRFSS) é um sistema de vigilância em saúde conduzido pelo CDC (Centers for Disease Control and Prevention). O dataset utilizado contém séries temporais e recortes geográficos com indicadores de obesidade, consumo de frutas e vegetais e atividade física de adultos americanos.

As principais variáveis de interesse incluem: taxa de obesidade por estado e ano, estratificada por faixa de renda, nível educacional, sexo e etnia.

3.2 Dataset 2: Food-at-Home Monthly Area Prices (USDA)

O dataset do USDA monitora mensalmente os preços regionais de gêneros alimentícios domiciliares, desagregado por área geográfica. Permite análise temporal das oscilações de custo e cruzamento geoespacial com os dados de saúde do BRFSS.

As principais variáveis de interesse incluem: preço médio mensal por categoria de alimento (frutas, vegetais, proteínas, processados) por região geográfica.

3.3 Integração dos Dados

A integração entre os dois datasets é realizada por meio de chave composta (**estado**, **ano**), permitindo o alinhamento temporal e geoespacial entre as variáveis de preço e os indicadores de saúde. A Tabela I sumariza as características principais dos datasets.

Table I. Características dos datasets utilizados

Atributo	BRFSS (CDC)	FAHMAP (USDA)
Granularidade	Estado / ano	Região / mês
Período	2012–2018	2012–2018
Nº de registros	110.880	1.020.600
Variável-alvo	Taxa de obesidade (%)	–

4. METHODOLOGY

O pipeline analítico compreende quatro etapas: pré-processamento, engenharia de features, análise correlacional e modelagem preditiva.

4.1 Pré-processamento e Integração

Os dados do BRFSS foram filtrados para o período 2012–2018, retendo registros com obesidade válida e excluindo territórios não-continentais e o agregado nacional. Foram produzidas duas visões: *cdc_geral* (taxa total por estado/ano, 357 observações) e *cdc_renda* (taxa estratificada por faixa de renda, 2.142 observações).

Os itens do USDA foram classificados em *healthy* (frutas, vegetais, leguminosas e laticínios magros; 48 códigos) e *processed* (snacks, refrigerantes e fast food; 22 códigos) por mapeamento de *EFPG_code*, e os registros mensais foram agregados em médias anuais por região. A integração foi realizada por chave composta (*Metroregion_code*, *Year*), resultando em datasets analíticos sem valores nulos. Todo o pipeline foi implementado com *pandas* e *DuckDB*.

4.2 Engenharia de Features e Modelagem

Foram derivadas três variáveis de preço: *Price_Healthy* e *Price_Processed* (médias anuais ponderadas em \$/100g por região) e *Price_Ratio* (razão entre ambas). A faixa de renda foi codificada ordinalmente (*Income_Num*, escala 1–6) e o termo de interação *Renda_x_PriceHealthy* foi construído com variáveis centradas para testar H3.

A modelagem foi conduzida em três cenários de features aninhados — M1 (preços absolutos), M2 (razão de preços) e M3 (razão + ano + dummies de região) — avaliando quatro modelos: Baseline (média), Regressão Linear (OLS com *StandardScaler*), Random Forest (300 estimadores, profundidade 5) e XGBoost [Chen and Guestrin 2016] (300 estimadores, profundidade 5, *learning rate* 0,1). A divisão treino/teste foi de 75%/25% (*random_state=42*).

5. EXPERIMENTAL SETUP

Os experimentos utilizam o dataset analítico unificado construído pelo JOIN entre os dados do BRFSS (CDC) e do USDA, totalizando 357 observações no recorte de obesidade geral e 2.142 no recorte estratificado por renda. A divisão treino/teste segue proporção 75%/25% (*random_state=42*), sem sobreposição entre partições, eliminando risco de *data leakage*.

As métricas de avaliação são MAE, RMSE e R^2 . O Baseline (média da variável-alvo) serve como referência mínima de desempenho. Os modelos avaliados são Regressão Linear (OLS com *StandardScaler*), Random Forest (300 estimadores, profundidade 5) e XGBoost (300 estimadores, profundidade 5, *learning rate* 0,1), testados em três cenários de features: M1 (preços absolutos), M2 (razão de preços) e M3 (razão + ano + dummies de região). Todos os experimentos foram implementados em Python 3.13, com *scikit-learn* 1.9, *xgboost* 3.0, *statsmodels* 0.14, *pandas* 3.0 e *DuckDB* 1.5.

6. RESULTS AND DISCUSSION

Evolução temporal de preços e obesidade por região (H1).. A Figura 1 apresenta a evolução dos preços médios e das taxas de obesidade nas quatro regiões entre 2012 e 2018. Os preços de alimentos saudáveis cresceram em todas as regiões — o Nordeste registrou os valores mais elevados (de \$0,51 para \$0,57/100g) e o Centro-Oeste os mais baixos (de \$0,47 para \$0,51/100g). As taxas de obesidade cresceram monotonicamente, com o Sul registrando os maiores índices (34,0% em 2018) e o Nordeste e o Oeste os menores ($\approx 28,0\%$).




Fig. 1. Evolução do preço médio de alimentos saudáveis, processados e da taxa de obesidade por região (2012–2018).

Correlações de Pearson entre variáveis de preço e obesidade (H1, H2).. A matriz de correlação global (Figura 2) revela que $Price_Healthy$ ($r = -0,291$) e $Price_Processed$ ($r = -0,335$) apresentam correlação negativa com a obesidade: regiões com preços absolutos mais altos (Nordeste e Oeste) são as de menor obesidade, evidenciando um efeito regional confundidor. A alta correlação entre as variáveis de preço ($r = 0,956$) confirma multicolinearidade, motivando o uso do $Price_Ratio$ ($r = 0,129$). Por região (Figura 3), Centro-Oeste ($r = 0,399$) e Oeste ($r = 0,236$) apresentam correlações positivas — suporte a H1 —, enquanto Nordeste ($r = -0,133$) e Sul ($r = -0,176$) exibem correlações negativas fracas, indicando moderação por fatores estruturais regionais — evidência de H2.




Fig. 2. Matriz de correlação de Pearson entre taxa de obesidade e variáveis de preço.




Fig. 3. Correlação entre *Price Ratio* e taxa de obesidade por região.

Efeito moderador da renda sobre a obesidade (H3). As Figuras 4 e 5 demonstram gradiente negativo claro entre faixa de renda e obesidade: <\$15k registra 34,8% e >\$75k registra 26,2% — diferença de 8,6 p.p., mantida ao longo de todo o período. A correlação de Pearson entre renda ordinal e obesidade é negativa e significativa ($r = -0,30$, $p < 0,05$), corroborando H3. A projeção linear para 2020 estima taxas próximas a 38% para a faixa <\$15k, com crescimento contínuo em todos os grupos.




Fig. 4. Taxa média de obesidade por faixa de renda (2012–2018).





Fig. 5. Evolução da obesidade por faixa de renda.

Desempenho comparativo dos modelos. A Tabela II sumariza as métricas dos quatro modelos nos três cenários. A Regressão Linear obteve R^2 de 0,063 (M1), 0,019 (M2) e 0,506 (M3). Random Forest e XGBoost atingiram $R^2 \approx 0,45$ já no M1, evidenciando relações não-lineares que a regressão não captura. No M3, a Regressão Linear supera levemente as árvores pois os controles de ano e região beneficiam mais o modelo linear neste dataset de dimensão reduzida. Em todos os cenários, o *Price_Ratio* perdeu significância após controle regional ($p = 0,75$ no OLS-M3), indicando que tendências temporais e disparidades regionais sistêmicas explicam a maior parte da variância (Figura 6).

Table II. Métricas de desempenho por modelo e cenário (teste, 25%).

Cenário	Modelo	MAE	RMSE	R ²
M1	Baseline	3,36	4,17	−0,005
	Reg. Linear	3,14	4,02	0,063
	Random Forest	2,26	3,07	0,455
	XGBoost	2,27	3,09	0,447
M2	Baseline	3,36	4,17	−0,005
	Reg. Linear	3,31	4,12	0,019
	Random Forest	2,55	3,37	0,341
	XGBoost	2,27	3,09	0,447
M3	Baseline	3,36	4,17	−0,005
	Reg. Linear	2,14	2,92	0,506
	Random Forest	2,27	3,09	0,447
	XGBoost	2,27	3,09	0,447

Fig. 6. R² ajustado dos modelos OLS nos três cenários (M1, M2, M3).

Em resumo, H1 é parcialmente confirmada: preços absolutos mais altos não implicam maior obesidade, mas o encarecimento relativo dos alimentos saudáveis frente aos processados se associa positivamente à obesidade no Centro-Oeste e no Oeste. H2 é confirmada pela variação regional do efeito. H3 é a hipótese mais robusta: populações de menor renda (<\$15k) apresentaram obesidade 8,6 p.p. acima das de maior renda (>\$75k) em todo o período analisado.

7. LIMITATIONS AND THREATS TO VALIDITY

Agregação geográfica. Os preços do USDA são disponibilizados para apenas quatro regiões censais, enquanto os dados de obesidade do BRFSS estão no nível estadual. Todos os estados de uma mesma região recebem o mesmo valor de preço, o que oculta variações hiperlocais e pode atenuar ou distorcer as correlações estimadas.

Período limitado. A interseção dos dois datasets cobre apenas 2012–2018, restringindo a generalização dos resultados. Eventos ocorridos após esse período — como as perturbações de preços e os impactos sobre obesidade associados à pandemia de COVID-19 — ficam fora do escopo da análise.

Associação, não causalidade. Os modelos estimam associações estatísticas entre preços e obesidade, mas não estabelecem relação causal. Fatores não observados — como cultura alimentar local, acesso a espaços de atividade física e políticas regionais de saúde — podem explicar parte da variância capturada.

8. CONCLUSION

Este estudo investigou se a disparidade de preços entre alimentos saudáveis e ultraprocessados é um preditor significativo das taxas de obesidade nos estados norte-americanos, integrando dados públicos do USDA e do CDC/BRFSS no período 2012–2018.

Os resultados confirmam parcialmente as três hipóteses. H1 recebe suporte nas regiões Centro-Oeste e Oeste, onde o encarecimento relativo dos alimentos saudáveis se associa positivamente à obesidade, mas não nas demais regiões, onde fatores estruturais locais predominam. H2 é confirmada pela heterogeneidade regional das correlações, indicando que o impacto da disparidade de preços varia conforme o contexto geográfico. H3 é a hipótese mais robusta: a diferença de 8,6 pontos percentuais de obesidade entre a faixa de menor e maior renda manteve-se estável ao longo de todo o período, evidenciando que a renda é o fator moderador mais determinante na relação entre acesso a alimentos saudáveis e risco de obesidade.

Do ponto de vista preditivo, os modelos de árvore (Random Forest e XGBoost) superaram a regressão linear nos cenários com apenas variáveis de preço ($R^2 \approx 0,45$ no M1), revelando relações não-lineares que modelos lineares não capturam. Com a adição de controles temporais e regionais (M3), a Regressão Linear atingiu o melhor desempenho geral ($R^2 = 0,506$, MAE = 2,14 p.p.), mas o *Price_Ratio* perdeu significância estatística, indicando que tendências temporais e disparidades regionais sistêmicas explicam a maior parte da variância observada.

Como trabalho futuro, propõe-se expandir a análise para dados mais recentes, incorporar variáveis socioeconômicas complementares e aplicar modelos com dados em painel para isolar o efeito causal dos preços sobre a obesidade.

REFERENCES

- CANALES, E., FAN, L., BUYS, D. R., AND CANTAVE, M. D. A market basket assessment: Prices and availability of healthy foods across SNAP-authorized food outlets in counties with high obesity rates in Mississippi. *Preventing Chronic Disease* vol. 18, pp. E99, 2021.
- CHEN, T. AND GUESTRIN, C. XGBoost: A scalable tree boosting system. In *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, pp. 785–794, 2016.
- FINKELSTEIN, E. A., STROMBOTNE, K. L., ZHEN, C., AND EPSTEIN, L. H. Food prices and obesity: A review. *Advances in Nutrition* 5 (6): 818–821, 2014.
- XU, X., VARIYAM, J. N., ZHAO, Z., AND CHALOUKKA, F. J. Relative food prices and obesity in U.S. metropolitan areas: 1976–2001. *PLOS ONE* 9 (12): e114707, 2014.